

Cours rédigé par :


Mathieu SEURIN

mathieu.seurin@devinci.fr

Nancy CHENDEB

nancy.chendeb@devinci.fr

ANALYSE DE DONNÉES



PROJET : EXPLORATION DES DONNÉES ET PRÉDICTION

- Date : à rendre avec le 15 mai avant 23:59 sur DVL
- A rendre : Un notebook avec vos expériences + un fichier de prédiction
- MAXIMUM 2 par groupe (au sein de votre groupe de TD)
 - **Aucune dérogation** : si groupe de TP impair, une personne sera seule (la notation en tiendra compte)
- Un projet « facile » : Note maximale 17/20, mais prend moins de temps
- Un projet plus dur : Note maximale 20/20, mais prendra plus de temps

PROJET SIMPLE : PRÉDICTION DE PRIX DE AIRBNB

Contenu :

2 fichiers .csv + un fichier d'explication

But : prédire le logarithme du prix du airbnb

Vous avez un ensemble d'informations brut sur le logement (le type de logement, les équipements, la ville dans laquelle se trouve le logement etc ...)

Vous allez passer un peu de temps à convertir des données textuelles en informations utilisables par un algo de machine learning. (Par exemple transformer le type de logement en catégorie numériques, indiquer si une télé est présente ou non etc ...)

Note maximale : 17/20

Note pour un projet moyen : 10/20



PROJET « DUR » : PRÉDICTION DE MATCH DE LIGUE1

Contenu :

8 fichiers .csv + un fichier d'explication

But : prédire le résultat du match de foot (victoire, nul, défaite)

Les informations sont un peu plus éparpillées entre les différents .csv, avec des informations sur les joueurs, les clubs, les matchs passés etc ..

Vous allez passer du temps à faire des fonctions qui agrègent les données de plusieurs .csv et qui créent des caractéristiques qui semblent importantes pour la prédiction du résultat

Note maximale : 20/20

Note pour un projet moyen : 8/20





EXIGENCES COMMUNES AUX DEUX PROJETS



Votre projet doit contenir :

- **Une partie exploration qualitative des données** (devrait vous prendre 1/3 de votre temps sur le projet) qui consiste à présenter les données avec votre notebook.
 - Le but de cette partie est de motiver certains choix pour la partie prédiction, pourquoi vous avez gardé certaines informations, pourquoi vous n'en avez pas utilisé d'autres. Par exemple, si vous trouvez une corrélation forte entre le prix de l'appartement et une caractéristique, afficher la matrice de corrélation. Vous pouvez afficher une carte montrant la répartition des prix par exemple etc ...
- **Une partie prédiction (2/3 de votre temps).**
 - Le but est de tester un maximum de choses : tester pleins de configuration de caractéristiques et de modèle différents. Tester différents pré-processing etc ...
 - Il faut que vous gardiez une trace sur le notebook de ce que vous avez fait et des différents résultats.
 - Vous avez le droit d'utiliser tous les outils de sklearn, il n'y a pas de contraintes.



LE MUSÉE DES HORREURS




TROP D'INFORMATIONS, PAS D'INFORMATIONS




LES SPECTROGRAMMES





property_type Vacat
cancellation_polic



\ CONTENU DU ZIP

Les données au format .csv

- 3 fichiers pour Airbnb (train, test, prediction_example.csv)
- 8 fichiers pour Ligue1

prediction_example.csv permet de regarder le format attendu pour la prédiction

Dans Airbnb se trouve un fichier exemple.ipynb, regardez-le attentivement car il contient un exemple très simple de pré-traitement et de prédiction pour les données Airbnb (même si vous faites le projet Foot, regardez-le)

EXIGENCES COMMUNES AUX DEUX PROJETS

Le rendu doit contenir :

- **Un notebook** avec de l'exploration qualitative de données (1/3 de la note) et les expériences de traitement + de prédiction (2/3 de la note).
 - Le notebook doit être clair et lisible c'est-à-dire : le code doit être commentée ET il doit y avoir des cellules au format markdown + des visualisations pour expliquer ce que vous avez fait (si il n'y a que des cellules de code, c'est qu'il y a un problème et vous aurez 7/20)
 - Les visualisations sont aussi obligatoires pour la partie prédiction, on doit comprendre ce que vous avez fait et pourquoi vous l'avez fait
- **Un fichier de prédiction** au format .csv avec vos prédictions les données cachées :
 - Il contiendra juste les id et votre prédiction (voir « prediction_example.csv » qui vous donne un exemple de la tête que doit avoir le fichier)

Votre score jouera dans la note finale **MAIS** il vaut mieux un projet bien illustré et clair avec un score pas terrible qu'un notebook illisible mais avec un très bon score

NOTATIONS

Barème et critère :

1/3 des points (Exploration des données):

- Présentation de la base
- Exploration qualitative de la base (distribution des données, répartition)
- Pertinence de présentation et des illustrations choisies
- Beauté des illustrations

2/3 des points (Prédiction) :

- Diversités des pré-traitements (beaucoup de features engineerings) : Partie la plus importante pour la prédiction
- Diversités des modèles testés
- Rigueur dans l'évaluation des modèles (définition d'une baseline, validation, comparaison entre pleins de modèles)
- Analyse des résultats

\ QUEL PROJET CHOISIR ?

Il vaut mieux prendre le projet simple et le faire sérieusement que prendre le projet dur et faire n'importe quoi (un projet dur mal fait n'aura que 8/20)

